

Hoja de decisión -- Banco de validación del detector de HR de ECG

Preparado por Claude Code para revisión del validador humano -- mismo rol que jugó validando el detector de BBB (leyó 50 ECGs, encontró 2 erratas de PTB-XL). Este documento no toma decisiones: presenta la evidencia y pide 3 juicios clínicos concretos. El código de producción de ECG Lab NO se tocó en este mini-arco.

Contexto: la Fase 2.4 (integración estrecha labs->UPS) dejó ECG diferido porque su heart_rate fiable requería un prominence_factor no establecido en el repo. Este banco corre el detector real del repo (clinical.ecg_analyzer.ECGAnalyzer.detect_r_peaks()) sobre 8 registros MIT-BIH reales, contra las anotaciones de cardiólogos (ground truth objetivo, PhysioNet .atr), en 6 valores de prominence_factor (0.3 default, 0.5, 0.7, 1.0, 1.5, 2.0).

Hallazgo principal (no esperado al iniciar el banco)

Los registros 117 y 108 comparten una causa raíz: en esta derivación (MLII), el QRS es predominantemente NEGATIVO. ECGAnalyzer.detect_r_peaks() usa scipy.signal.find_peaks(), que solo busca máximos POSITIVOS -- el algoritmo nunca ve el latido real en estos registros, sin importar el prominence_factor (VPP tope ~0.53 en el 117; sensibilidad 0.15-0.18 en el 108 en TODO el barrido). Esto no es un problema de umbral -- es una limitación estructural del detector. Ver las tiras de estos dos registros en el PDF adjunto: el triángulo rojo (pico detectado) marca sistemáticamente una onda positiva secundaria, nunca la X verde (el verdadero QRS, negativo).

Otros hallazgos

- Registro 207 (fibrilación/flutter ventricular + ruido): sensibilidad nunca supera ~0.36 en ningún prominence_factor probado -- caso fuera del alcance de este detector, cualquiera sea el parámetro.
- Registro 233 (ruidoso): el ERROR de HR promedio se ve enganosamente bueno (<3bpm en casi todo el barrido) pese a sensibilidad/VPP imperfectos -- falsos positivos y negativos se cancelan en el promedio. Advertencia: evaluar solo por error de HR promedio puede ocultar un detector poco fiable.
- Registros limpios (100, 103) y BRD (118): prominence_factor=1.0 da resultados excelentes (sensibilidad/VPP >=0.98, error de HR <1bpm).
- Registro 228 (arritmia real, PVCs): 1.0 minimiza el error de HR (0.3bpm) pero sensibilidad/VPP quedan en ~0.85-0.87 -- umbrales más altos pierden latidos ectópicos de menor amplitud.

Las 3 preguntas para el experto

1. Conjunto de registros

El conjunto (100, 103, 117, 108, 228, 207, 233, 118) se eligió por cribado cuantitativo propio (proporción T/R, carga arritmica, voltaje QRS, ruido) sobre 23 registros candidatos de MIT-BIH -- PROVISIONAL, no una selección clínica experta. ¿Cubre las morfologías que de verdad rompen detectores de R, o falta alguna (p.ej. fibrilación auricular sostenida, marcapasos/217, otras derivaciones además de MLII)?

2. Ground truth

Las anotaciones .atr de MIT-BIH (picos de latido marcados por cardiólogos, disponibles vía wfdb.rdann) se usaron como referencia objetiva. PTB-XL NO tiene anotaciones de latido descargables (confirmado: 404 al pedir el .atr) -- solo códigos diagnósticos a nivel de registro. ¿Las anotaciones de MIT-BIH bastan como referencia para decidir el parámetro, o hace falta que usted marque el HR a mano en algún caso (p.ej. para confirmar un límite dudoso)?

3. Criterio de aceptación

¿Que margen de error de HR (o que sensibilidad/VPP mínimos) es tolerable para que ECG Lab escriba heart_rate al gemelo? ¿Que debe pasar con un registro que cae fuera de ese margen -- declinar la escritura de ese registro específico, o un umbral de calidad de señal previo (p.ej. rechazar si $VPP < X$)? ¿Bendice `prominence_factor=1.0` como el valor a usar, otro valor, o considera que el detector necesita un cambio estructural (p.ej. buscar también picos negativos, ver el hallazgo principal) antes de que CUALQUIER parámetro sea aceptable para escribir al UPS?

Archivos de este banco

- `tiras_ecg_picos_marcados.pdf`: 8 registros x 2 parámetros (0.3 y 1.0), picos detectados vs anotaciones, con portada y leyenda.
- `tabla_comparativa_detector_hr.xlsx`: 48 filas (8 registros x 6 `prominence_factor`) con HR, error, sensibilidad, VPP, TP/FP/FN; segunda hoja de contraste 0.3 vs 1.0 con veredicto por registro.
- Este documento (`hoja_decision_experto.pdf`).